二面速记卡

腾讯 IEG · 洛克王国：世界 · 斯嘉丽 Coach Agent

仓库 roco-coach @ 2e62a73b（2026-10-06）· 数字见 EVIDENCE-LEDGER · 不跑全量测试、不报“全绿”

一、开口六句

1. **规则引擎决定事实，模型只决定措辞。**（伤害/合法性/顺序/状态由引擎算；模型只理解、查证、组织语言）
2. **该不该调工具由代码定；调哪个、下一步看回执由模型定。**回执上限 3，首枪后最多再规划 2 次；**stopped 22 种**取值域有判据。
3. **回答里的数字/技能名/因果必须命中证据包**，否则整条降级成本地结论；但只保证“有出处”，不保证“语义对”。
4. **旧建议三层失效**：epoch 取消在途、交付前验 stateToken、客户端断连则服务端中止上游。
5. **检索我没赢**：四臂最好臂只 +2.68pp、不显著（p=0.45，CI 含 0）；保留关键词基线、公开负结论。
6. **学习是可修正假设**：只算没提示的独立行动，3 次跨局才说“出现迁移迹象”，不写“已掌握”。

二、八个数字（都能现场指到文件）

- **22** 种停止原因 / **12** 个工具合同 / 回执上限 3 / 首枪后再规划 2 次
- **2,084** 条判据 / **187** 文件（今天 2,068 过 / 15 红 / 1 skip）/ **27** 个发布门禁套件（清单，不写全绿）
- **15/15** 注入自检翻红 / **1,152** 参数工具路由头，16 条留出 **8→15**
- 四臂（128 条，归档）：关键词 88.39% / 混合 90.18% / 反例臂 91.07%；最好臂 +2.68pp、p=0.45 不显著
- policy-first：两轮 **286–288/288**、0 条由通转败（单臂 local_4b，方差大）
- **622** 图鉴 / **530** 可玩 / **542** 冻结 / **540** 六维 / **80** 按需；「48」只是目录名
- 云端 3 轮：HTTP200、raw==delivered==UI、fallback=0（2026-10-06 归档，今天未重发）

三、五个追问的落点

- **“多步/ReAct ?”** 真 Agent 只有 `gatherAgentEvidenceOnce`；真实模型记录最大 1 次工具，多步只有确定性测试——不把代码能力冒充模型能力。
- **“RAG 价值 ?”** 不是准确率，是带条件/反例/版本的可核查证据；没赢的实测 + 负例拒答 56.25% 一起讲。
- **“怎么防过期 ?”** `scheduler.js` epoch+abort、`app.js` stateToken/身份、服务端断连中止。
- **“怎么证明学习 ?”** 只算无提示独立行动；阈值 3 次/2 局/合理率 75%；没有真人数据就直说没有。
- **“你本人做了什么 ?”** 需求、交互、验收、AI 协作实现；不把 AI 代码说成手写；现场给变体就按“定位 → 找守卫 → 写反例 → 最小改 → 验证”走。

四、演示与安全命令

`npm run test:roco-quality`（77/77）

`npm run test:slow-model`

`node -e "...AGENT_STOPS.length"`（22）

不要跑：`test:unit`（今天 15 红）、`verify:release`（不可跑）、任何 `eval:live`（付费）。演示服务：`PORT=8910 npm start` + `curl :8910/api/roco/status`；挂了就用离线三件套/录屏。

五、反问与红线

反问（选 2）：三引擎里最耗人力是哪一环？ “什么时候不说/要不要主动干预”有显式判据吗？ 实习生先补游戏理解还是 Agent 工程?

红线：不说“训练/微调了 DeepSeek”“做了多 Agent 系统”“RAG 显著提升”“已接入游戏”“准确率 90%”“比斯嘉丽强”；不把团队成绩、AI 生成代码说成个人独立完成；官方数字（100 万条/82%/90%+/40s→2-10s/+20%）必须带“采访里提到”。